

第1课 为什么需要 vLLM

什么是vllm
为什么需要vllm

什么是vllm

vLLM 是一个面向大语言模型推理与在线服务的高性能执行系统。它通过动态批处理、KV Cache 管理、高效注意力计算和分布式执行，提高 GPU 利用率、推理吞吐量和服务并发能力。

更口语化地说：

vLLM 位于大模型和业务请求之间，负责把不断到来的请求组织起来，管理有限的 GPU 显存，并高效地执行模型推理。

为什么需要vllm

大模型能够运行，并不等于能够被高效地部署成在线服务。vLLM 解决的是大模型推理服务中的性能、显存、并发和工程化问题。

推理服务问题	vLLM 中的对应机制
GPU 利用率不高	Continuous Batching
KV Cache 预留浪费和碎片	Block Table、PagedAttention
相同 Prompt 重复计算	Prefix Caching
长 Prompt 阻塞 Decode	Chunked Prefill
请求之间争抢计算和显存	Scheduler
每次执行的 CPU/GPU 开销较高	CUDA Graph、编译与融合算子
单卡放不下或吞吐不足	TP、PP、DP
...	...

vLLM 不是大模型，也不是模型训练框架；它是让已经训练好的模型能够被高效部署和服务的推理系统。