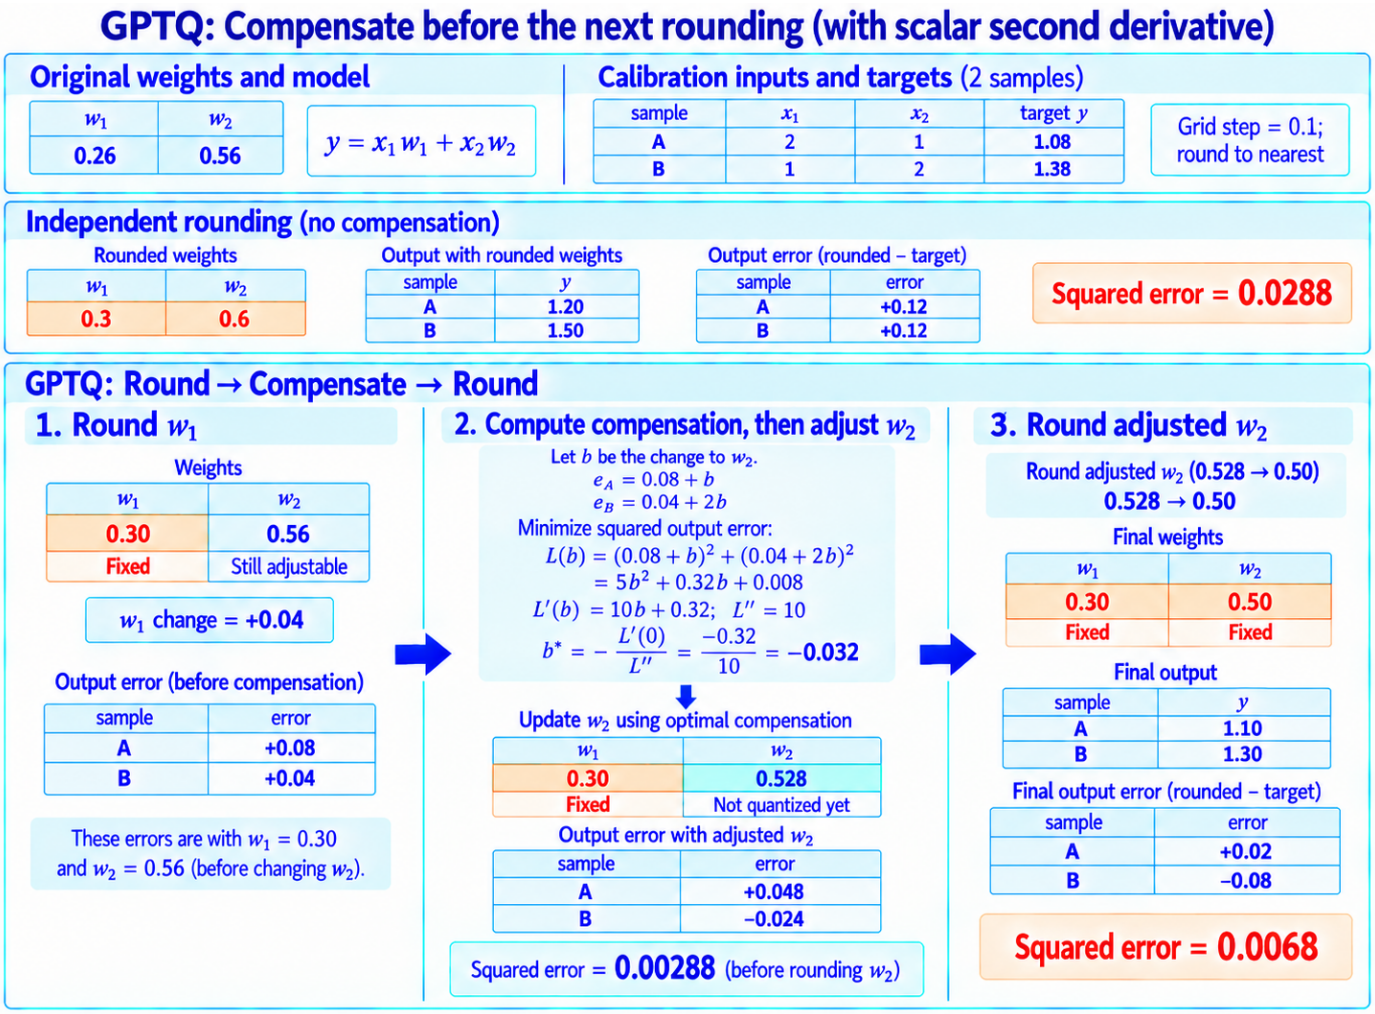
第8课 GPTQ：逐项量化与输出误差补偿

GPTQ 是一种训练后权重量化方法。名称结合了 GPT 与 PTQ：GPT 指生成式预训练 Transformer（Generative Pre-trained Transformer），PTQ 指训练后量化（Post-Training Quantization）。它用少量校准输入衡量线性层的输出变化，在量化一项权重后调整尚未量化的权重，补偿舍入误差。

一、逐项量化与补偿量计算

取两个权重 0.26、0.56，使用两组校准输入比较原输出和量化后输出。量化步长固定为 0.1，权重只能落在它的整数倍上。例如 0.26 编码为整数 3，还原为 0.3；图中参与输出计算的都是还原值。



二、GPTQ 误差补偿的数学原理

沿用第一节的两组输入 $(2,1)$ 、$(1,2)$ 和权重 $[0.26, 0.56]$，将两项权重的改变量记为 a, b 。

1. 输出误差与二次损失

输入按行排列，改变量按列排列。调整权重后，两组输出分别变化 $2a+b$ 和 $a+2b$：

$$X=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix},\qquad \delta=\begin{bmatrix}a\\ b\end{bmatrix},\qquad X\delta=\begin{bmatrix}2a+b\\ a+2b\end{bmatrix}.$$

把两组输出误差平方后相加，得到损失：

$$L(\delta) = \|X\delta\|_2^2 = (X\delta)^\top (X\delta) = \delta^\top X^\top X\delta,$$
$$L(a,b) = (2a+b)^2 + (a+2b)^2 = 5a^2 + 8ab + 5b^2.$$

第一项舍入到 0.30 后， $a = 0.04$ 已经固定。需要求的是：第二项改变多少，才能让这个损失最小。

2. 梯度与 Hessian：逐项求导与二次型公式

逐项求导。 先对 a, b 求一次偏导，排成梯度：

$$\nabla L = \begin{bmatrix} \dfrac{\partial L}{\partial a} \\ \dfrac{\partial L}{\partial b} \end{bmatrix} = \begin{bmatrix} 10a + 8b \\ 8a + 10b \end{bmatrix}.$$

再求一次，得到 Hessian（由所有二阶偏导数按变量顺序排列成的矩阵）：

$$H = \begin{bmatrix} \dfrac{\partial^2 L}{\partial a^2} & \dfrac{\partial^2 L}{\partial b\,\partial a} \\ \dfrac{\partial^2 L}{\partial a\,\partial b} & \dfrac{\partial^2 L}{\partial b^2} \end{bmatrix} = \begin{bmatrix} 10 & 8 \\ 8 & 10 \end{bmatrix}.$$

使用二次型公式。 逐项求导适用于一般函数；当前损失是对称二次型，还可以直接使用公式：对固定的对称矩阵 A， $f(x) = x^\top Ax$ 的梯度为 $2Ax$，Hessian 为 $2A$。取 $x = \delta$、$A = X^\top X$，得到相同的结果：

$$H = 2X^\top X = 2\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 10 & 8 \\ 8 & 10 \end{bmatrix},$$
$$\nabla L = 2X^\top X\delta = H\delta = \begin{bmatrix} 10a + 8b \\ 8a + 10b \end{bmatrix}.$$

Hessian 不随 a, b 变化，因此梯度是改变量的线性函数，求补偿可以转成解线性方程。

3. 舍入约束下的补偿量求解

第一项已固定，只有 b 可以调整。令第二项的偏导为零：

$$\frac{\partial L}{\partial b} = 8a + 10b = 0 \quad\Longrightarrow\quad 0.32 + 10b = 0 \quad\Longrightarrow\quad b = -0.032.$$

第二项变为 $0.56 - 0.032 = 0.528$，随后再舍入。第一项不再调整，所以不要求它的偏导为零。本例关于 b 的二阶导数为 10，损失向上弯，偏导为零的位置就是最低点。

有更多权重时，联立求解仍然适用。例如增加第三项改变量 c，将输入扩展为 $(2,1,1)$、$(1,2,1)$、$(0,0,1)$：

$$L(a,b,c) = (2a+b+c)^2 + (a+2b+c)^2 + c^2.$$

第一项仍固定为 $a = 0.04$，让另外两项的偏导为零：

$$\begin{cases} \dfrac{\partial L}{\partial b} = 8a + 10b + 6c = 0, \\ \dfrac{\partial L}{\partial c} = 6a + 6b + 6c = 0. \end{cases}$$

代入 $a = 0.04$：

$$\begin{cases} 10b + 6c = -0.32, \\ 6b + 6c = -0.24. \end{cases}$$

两式相减，得到 $4b = -0.08$，所以 $b = -0.02$；代回得到 $c = -0.02$。**固定一项后，所有尚可调整的项一起参与补偿。** Hessian 正定时，这组方程的解使当前舍入约束下的损失最小。

4. 逆 Hessian 与补偿计算的复用

一层可能有几千列权重，每量化一列都要补偿后续列。若每轮重新分解系数矩阵、求解方程，会产生大量重复计算。GPTQ 将解写成逆 Hessian 的比例，以便复用求解信息。

回到两项权重的算例。把梯度记为 $g = [g_1, g_2]^\top = H\delta$。补偿完成时，第二项的偏导 $g_2 = 0$，第一项已固定，g_1 可以不为零。本例 Hessian 正定，记 $G = H^{-1}$，两边左乘 G：

$$Gg = GH\delta = \delta, \qquad G = \frac{1}{36}\begin{bmatrix} 10 & -8 \\ -8 & 10 \end{bmatrix}.$$

代入 $g_2 = 0$，再按行展开乘法：

$$\begin{bmatrix} a \\ b \end{bmatrix} = G \begin{bmatrix} g_1 \\ 0 \end{bmatrix}, \qquad \begin{aligned} a &= \frac{10}{36} g_1 - \frac{8}{36} \times 0 = \frac{10}{36} g_1, \\ b &= -\frac{8}{36} g_1 + \frac{10}{36} \times 0 = -\frac{8}{36} g_1. \end{aligned}$$

两项都由同一个 g_1 乘系数得到。把第二式写成第一式的倍数，就不必单独计算 g_1：

$$\begin{aligned} b &= \frac{-8/36}{10/36}\left(\frac{10}{36} g_1\right) = \frac{G_{21}}{G_{11}} a, \\ &= -0.8 \times 0.04 = -0.032. \end{aligned}$$

多项权重时，**本轮方程组只包含当前舍入的第 i 项和后续尚可调整的项。** 之前已经量化并固定的项，本轮新增改变量为零，不再参与求解，也不要求它们的偏导为零。这里的 H, G, δ, g 都限定在本轮参与求解的位置，δ 表示从本轮开始时的权重出发的新增改变量。

在这个范围内，第 i 项的改变量固定为 $q_i - w_i$，其余可调项的偏导都为零，只有 g_i 可能非零。因此，$\delta = Gg$ 的各行只剩第 i 列的贡献：

$$\delta_i = G_{ii} g_i = q_i - w_i, \qquad \delta_j = G_{ji} g_i.$$

把第二式写成第一式的倍数，得到通用补偿公式：

$$\delta_j = \frac{G_{ji}}{G_{ii}}\delta_i = (q_i - w_i)\frac{G_{ji}}{G_{ii}}.$$

q_i 是当前权重量化并还原后的值， j 是其他尚可调整的位置。**舍入改变量乘以逆矩阵中的系数比例，就是补偿量。**

下一轮从已补偿的权重继续量化。上面的公式用本轮可调范围对应的逆 Hessian 表达补偿量；GPTQ 实现则预先计算逆 Hessian 并做 Cholesky 分解，逐列使用同一份分解结果中的对应行，无需每轮重新求逆。实现还会在求逆前给 Hessian 的对角线加入小正数，提高数值稳定性；此时求解的是带阻尼的二次损失。论文 §3–§4

三、量化权重的保存与 vLLM 推理

量化后的权重如何保存

前面的计算使用还原后的权重值。第一节中，0.26 量化后变成 0.30；模型文件可以保存整数编码 3 和尺度 0.1，推理时由 $3 \times 0.1 = 0.30$ 得到计算所需的权重值。

带零点的还原规则为：

$$\widehat{w} = s(c - z).$$

c 是整数编码， s 是尺度， z 是代表数值零的编码。本例 $c = 3, s = 0.1, z = 0$ 。为减少额外存储，许多权重共用一组尺度和零点；还需要记录每个权重使用哪一组参数。

常见 GPTQ 格式保存以下内容：

保存项	作用
`qweight`	打包保存低位整数编码，例如用 4 位表示编码 3
`scales`	每组的量化尺度，例如 0.1
`qzeros`	每组的零点编码
`g_idx`	标明各输入通道对应的权重属于哪一组

主要的存储节省来自权重编码从 16 位降到 4 位。尺度、零点和分组信息也占空间，但由多项权重共享或按输入通道记录，整体存储量仍然显著减少。

vLLM 如何加载和计算

在 **vLLM v0.25.1** 中，GPTQ 线性层 加载这些参数，再整理成选定内核需要的布局。

以 W4A16 配置为例，权重以 4 位存储，输入激活使用 FP16 或 BF16。Marlin 内核调用 将输入、打包权重和量化参数一起交给内核。内核按片段读取编码，结合尺度和零点还原权重并计算，无需先将整个权重矩阵展开成高精度形式。

校准和误差补偿在离线量化时完成；vLLM 推理直接使用保存好的量化结果。