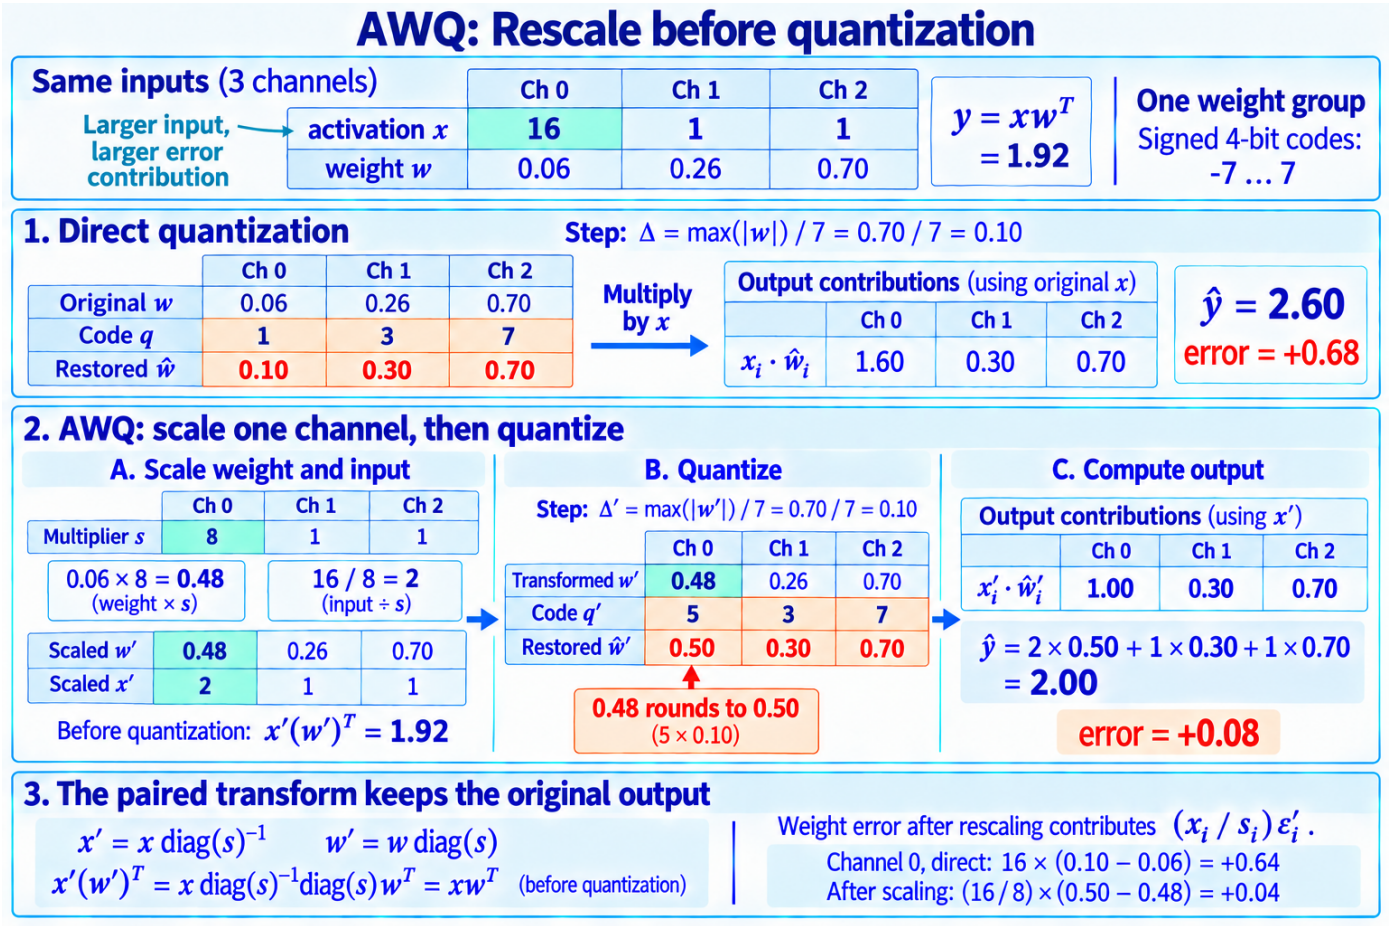
第9课 AWQ：激活感知与通道缩放

AWQ（Activation-aware Weight Quantization，激活感知的权重量化）是一种训练后权重量化方法。它根据校准输入的激活统计选择通道倍率，放大重要通道的权重，同时反向缩小对应输入，保持量化前的输出不变。通过合适的缩放，减少权重量化造成的输出误差。

一、通道缩放如何减少量化误差

取一个 token、一个输出通道，输入为 $[16, 1, 1]$，权重为 $[0.06, 0.26, 0.70]$。三个权重放在同一量化组，原输出为 1.92。第一项权重虽然最小，但输入为 16：同样大小的权重误差，在第一项上会被放大 16 倍。

本例使用对称 4 位编码 $-7, \dots, 7$，组步长 Δ 由最大权重决定，为 $0.70/7 = 0.10$。图中对比直接量化，以及第一通道权重放大 8 倍、输入缩小 8 倍后的量化：



二、通道缩放的原理与校准搜索

1. 激活大小与输出误差

线性层的一个输出为 $y = \sum_j x_j w_j$。若权重还原后的误差为 $\epsilon_j = \widehat{w}_j - w_j$，则：

$$\Delta y = \sum_j x_j \epsilon_j.$$

同样大小的权重误差，会被较大的输入激活放大。因此，AWQ 用激活统计寻找需要重点保护的权重通道；激活本身仍可保持 16 位。

2. 等价缩放与有效量化刻度

把第 j 个通道的权重乘以正数 s_j，输入除以同一个数，量化前的乘积不变：

$$\frac{x_j}{s_j}(s_j w_j) = x_j w_j.$$

量化后，放大的权重产生舍入误差 ϵ'_j，该项的输出误差为：

$$\begin{aligned}\Delta y_j &= \frac{x_j}{s_j}(s_j w_j + \epsilon'_j) - x_j w_j \\ &= \frac{x_j}{s_j}\epsilon'_j.\end{aligned}$$

第一章把 0.06 放大为 0.48，组步长仍为 0.10。换回原权重的尺度，相邻刻度间距就是：

$$\text{有效刻度间距} = \frac{\text{缩放后的组步长}}{\text{通道倍率}} = \frac{0.10}{8} = 0.0125.$$

缩放后的 0.48 舍入到 0.50，除回倍率后得到 0.0625，比直接舍入得到的 0.10 更接近原权重 0.06。**重要通道仍使用 4 位编码，但在原权重尺度上获得了更细的刻度。**

倍率并非越大越好。若放大的权重成为组最大值，组步长也会变大，其他通道的误差可能增加。因此，候选倍率要比较整体输出误差。论文 §3.2

3. 校准数据如何决定倍率

校准数据提供两类信息：**各通道通常有多大，以及采用某组倍率后，实际输出误差有多大。** 前者用于生成候选，后者决定最终选择。

① **统计通道幅度。** 沿用第一章的权重 $[0.06, 0.26, 0.70]$，加入第二个校准 token：

token	第一通道	第二通道	第三通道
0	16	1	1
1	16	−1	1

对每个通道，先取激活绝对值，再对校准 token 求均值，得到 $\mathbf{s_X} = [16, 1, 1]$。第二通道的统计量为 $(|1| + |-1|)/2 = 1$，避免正负激活相互抵消。激活统计代码

② **生成候选倍率。** $\mathbf{s_X}$ 表示各通道的平均激活幅度，$\mathbf{s}$ 表示通道倍率。候选倍率按元素取幂：

$$\mathbf{s} = \mathbf{s_X}^{\alpha}, \qquad s_j = (s_{X,j})^{\alpha}.$$

统一乘一个倍数，不会改变通道之间的倍率之比；取幂则可以用一个 α 调节这个比例。在 $[0, 1]$ 内，α 越接近 0，各通道倍率越接近；越接近 1，倍率之比越接近原激活幅度之比。$\alpha = 0$ 时各通道倍率都为 1，$\alpha = 1$ 时倍率与激活幅度成正比。这个幂函数用于生成候选，最终仍以输出误差选择倍率。

本例三个通道的候选倍率为 $\mathbf{s} = [16^{\alpha}, 1^{\alpha}, 1^{\alpha}] = [16^{\alpha}, 1, 1]$。取 $\alpha = 0, 0.25, 0.5, 0.75$，第一通道倍率依次为 1、2、4、8，另外两个通道始终为 1。搜索一个 α，就能生成整组倍率，不必为每个通道分别枚举。

论文 将搜索范围设为 $[0, 1]$，在不缩放与按激活幅度同比例缩放之间选择。$\alpha > 1$ 虽然也能计算，但会进一步放大通道倍率差异，可能抬高组内最大权重，使量化刻度变粗、增加其他通道的误差。因此，$[0, 1]$ 是控制缩放强度的搜索设计，并非数学限制。

缩放搜索 枚举 $0, 0.05, \ldots, 0.95$ 共 20 个候选值，并对倍率设置正数下限，再统一乘一个归一化系数，不改变通道之间的倍率比例。下面的表格展示归一化前的相对倍率。

③ 模拟量化并比较输出。 对每个候选，先按倍率变换权重，重新计算各组的量化步长，再量化并还原。配合逆缩放后的输入，计算全部校准 token 的输出，和原输出比较。每个候选都从同一份原始权重开始，避免前一个候选的量化误差影响后一个候选。

用 y_t 表示第 t 个 token 的原输出，$\hat{y}_t$ 表示候选方案的量化输出。两个 token 的误差平方均值为：

$$E = \frac{1}{2}\sum_{t=0}^{1}(\hat{y}_t - y_t)^2.$$

下面选取四组容易手算的候选。还原权重已除回对应通道倍率，恢复到原权重尺度，可直接与原输入相乘。 例如，第一通道倍率为 2 时，$0.06 \times 2 = 0.12$ 舍入到 0.10，再除以 2 得到 0.05；倍率为 4 时，$0.06 \times 4 = 0.24$ 舍入到 0.20，再除以 4 也得到 0.05。

α	第一通道倍率	第二通道倍率	第三通道倍率	组步长 Δ	原尺度还原权重 $\widehat{\mathbf{w}}$
0	1	1	1	0.10	[0.10, 0.30, 0.70]
0.25	2	1	1	0.10	[0.05, 0.30, 0.70]
0.5	4	1	1	0.10	[0.05, 0.30, 0.70]
0.75	8	1	1	0.10	[0.0625, 0.30, 0.70]

两个 token 的原输出分别为 1.92、1.40。第一行直接量化后的输出分别为 2.60、2.00，输出误差就是 $2.60 - 1.92 = 0.68$ 和 $2.00 - 1.40 = 0.60$ 。其余候选同样计算：

α	token 0 输出误差	token 1 输出误差	误差平方均值 E
0	+0.68	+0.60	0.4112
0.25	−0.12	−0.20	0.0272
0.5	−0.12	−0.20	0.0272
0.75	+0.08	0	0.0032

最后一列将同一行的两个输出误差平方后求平均。例如，最后一行 $E = (0.08^2 + 0^2)/2 = 0.0032$ ，在这四组候选中误差最小，因此选择 $\alpha = 0.75$ ，对应第一章的倍率 $[8, 1, 1]$ 。

倍率从 2 增加到 4，还原权重和误差却没有变化：倍率增大并不保证每次都能改善舍入结果。**最终倍率由全部校准输入的输出误差决定。** 实际模型会比较所评估线性层或模块的全部输出元素，取误差平方均值；搜索只执行前向计算，不通过反向传播更新模型。

量化时还会搜索裁剪阈值：限制组内极端权重，尝试用它们增加的误差换取其他权重更细的刻度，同样以输出误差选择阈值。

AWQ 的通道缩放可以与 GPTQ 的误差补偿结合：先对通道做等价缩放，再由 GPTQ 量化变换后的权重并补偿舍入误差。论文表 9 展示了两者结合的量化方案。

三、AWQ 模型的保存与 vLLM 推理

缩放如何保存到模型

选定倍率后，需要把“权重放大、输入逆缩放”应用到模型参数。例如，将前序 LayerNorm 或 RMSNorm 的可学习权重及偏置（若有）除以倍率，使其输出按通道缩小，再把使用这份输出的后续线性层对应权重列乘以倍率。这样输入在进入线性层前已经完成逆缩放，无需每次推理重新搜索倍率。

随后量化权重，保存打包整数编码 `qweight`、组尺度 `scales` 和零点 `qzeros`。第8课介绍的还原规则仍然适用：**通道倍率改变模型的参数表示，组尺度与零点用于解释量化编码，两者用途不同。**

vLLM 如何加载和计算

在 **vLLM v0.25.1** 中，AWQ 加载处理 将文件中的打包编码整理为选定内核需要的格式。这一步改变存储布局，保持量化权重的数值。

以 W4A16 的 Marlin 路径为例，权重以 4 位存储，输入激活使用 FP16 或 BF16。内核调用 将输入、打包权重、尺度和零点一起用于计算，按片段还原权重并做矩阵乘法，无需先展开整个高精度权重矩阵。

校准、缩放搜索和裁剪在离线量化时完成，vLLM 推理使用保存好的模型参数和量化权重。