第10课 SmoothQuant：激活平滑与 W8A8 计算

SmoothQuant 是一种面向 W8A8（8 位权重、8 位激活）的训练后量化方法。它缩小激活中数值特别大的通道，同时放大对应权重，保持量化前的输出不变，减小直接量化激活造成的误差，使权重和激活都能以 INT8 参与计算。

一、从 INT8 计算到激活平滑

1. INT8 的硬件收益

GPU 对不同精度的矩阵乘法提供不同的计算吞吐量。例如，NVIDIA A100 的 Tensor Core（专门执行矩阵乘加的硬件单元）在稠密计算下，FP16 理论峰值为 312 TFLOPS，INT8 为 624 TOPS；按运算次数计算，INT8 的理论吞吐量是 FP16 的两倍。A100 官方规格

要使用 INT8 × INT8 这条计算路径，权重和激活都需要量化为 INT8。 这就是本课的 W8A8：权重（Weight）和输入激活（Activation）都以 8 位参与计算。相比 FP16/BF16 每个数占 2 字节，INT8 编码只占 1 字节，还能减少数据存储与传输。论文 §1–2 实际推理收益还取决于矩阵大小、数据搬运和量化开销，不能直接等同于理论吞吐量的提升。

2. 激活量化的难点与平滑方法

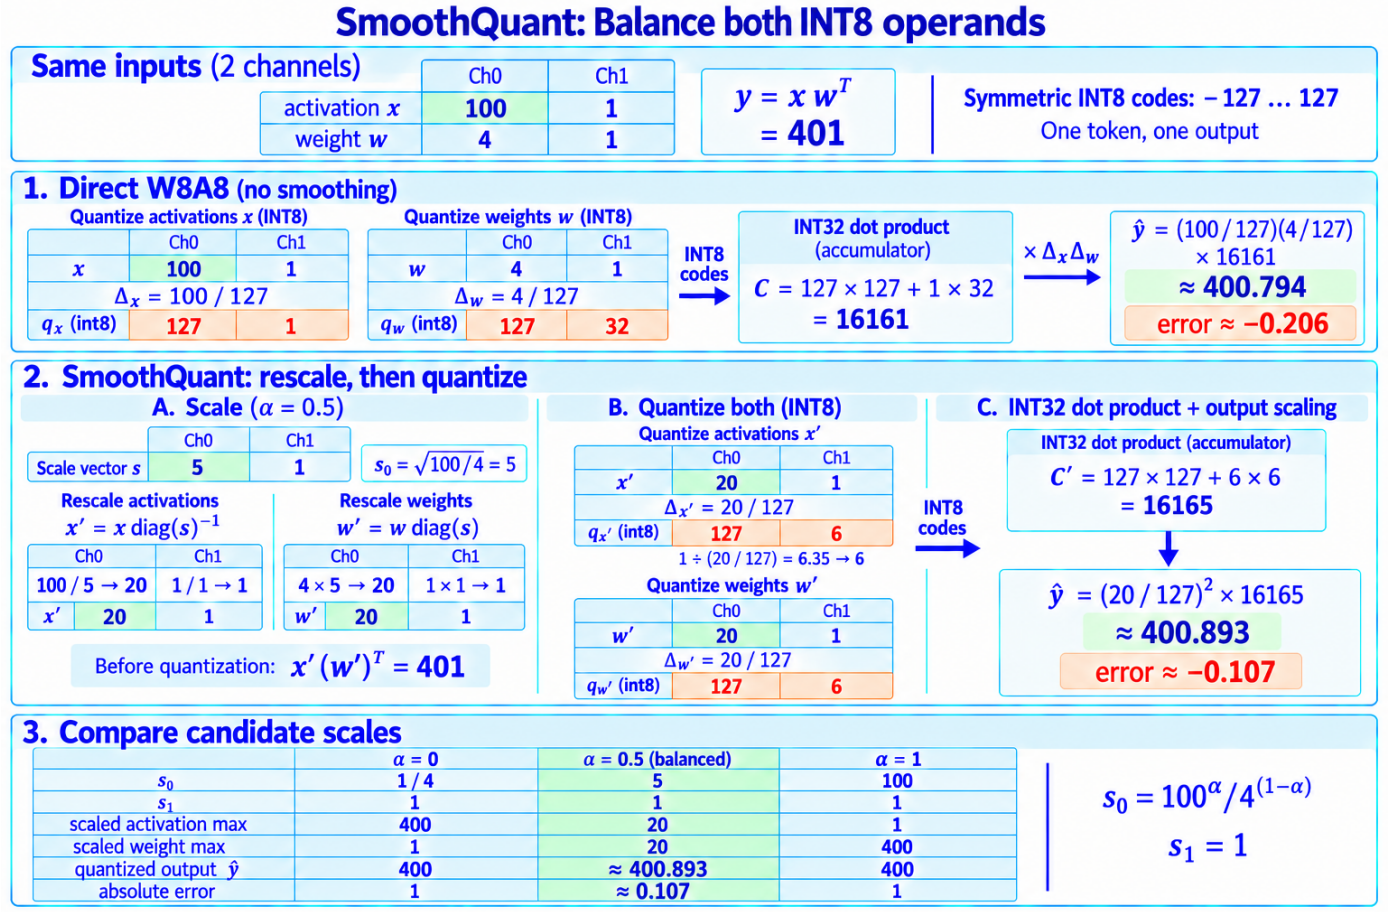
要获得这些收益，首先得解决激活量化的精度问题。当一组激活共用量化步长时，需要用有限的整数刻度覆盖这组数的范围。少数特别大的值会拉大刻度间隔，使大量较小值的舍入误差增大，进而影响模型精度。

异常大值往往集中在少数固定的激活通道，而权重相对容易量化。SmoothQuant 因此将大幅度激活通道除以一个倍率，再将对应权重乘以同一倍率。两者的乘积不变，激活中的异常大值却被缩小，再对两侧做 INT8 量化。论文 §3–4

3. 两通道量化示例

取一个 token、一个输出通道，输入为 $[100, 1]$，权重为 $[4, 1]$，原输出为 401。本例使用对称 INT8 编码 $-127, \dots, 127$：分别将激活和权重的最大绝对值除以 127，得到各自的量化步长；再将数值除以步长，舍入为整数编码。

图中对比直接量化与先平滑再量化。error 表示还原后的输出减去原输出，absolute error 是其绝对值；比较哪个结果更准确时，看绝对误差。



二、平滑倍率的设计与校准

1. 等价缩放与两侧误差

第 j 个输入通道除以正数 s_j，对应权重乘以它，量化前的乘积不变：

$$\frac{x_j}{s_j}(s_j w_j) = x_j w_j.$$

AWQ 也使用“输入除以倍率、权重乘以倍率”的变换。**区别在于缩放之后：AWQ（W4A16）只量化权重，输入仍保留 16 位浮点；SmoothQuant（W8A8）则把输入和权重都量化为 INT8。** 因此，这里既要减小激活的量化误差，也要避免放大后的权重产生过大的量化误差。

2. 缩放倍率与参数选择

选择倍率的目标，是降低输入和权重都量化后的输出误差。

用一个参数 α 生成各通道的候选倍率。 X_j 表示校准数据中第 j 个输入通道的激活， W_j 表示与该通道相乘的全部权重，倍率按两侧的最大绝对值计算：缩放公式

$$s_j = \frac{\max(|X_j|)^{\alpha}}{\max(|W_j|)^{1-\alpha}}, \qquad 0 \le \alpha \le 1.$$

改变 α ，就得到一组新的通道倍率。在图中的例子里，第一通道的激活幅度为 100，权重幅度为 4，代入得到：

$$s_0 = \frac{100^{\alpha}}{4^{1-\alpha}}.$$

取 $\alpha = 0, 0.5, 1$ ，第一通道倍率分别为 $1/4, 5, 100$ ，对应图底部的三种选择；第二通道两侧幅度都是 1，倍率始终为 1。

将候选倍率用于缩放，再模拟两侧的 INT8 量化，比较输出误差。图中 $\alpha = 0$ 或 1 时，一侧的数值变成 $[400, 1]$ ，较小的 1 被舍入为编码 0，第二通道的贡献丢失，输出因此变为 400。 $\alpha = 0.5$ 时，两侧都为 $[20, 1]$ ，在这三个候选值中输出绝对误差最小。

这里 $\alpha = 0$ 仍会缩放，不等于图上方直接使用原始输入和权重的"不平滑"基线。**两侧幅度相等也不保证误差最小。**实际校准需要在多条输入上评估候选参数，也可以依据量化后模型的任务表现选择 α 。参数选择

3. 校准与参数变换

1. **统计通道幅度。** 用校准文本运行模型，在各线性层输入处收集每个通道的最大绝对值，同时计算对应权重的最大绝对值。激活统计
2. **选择参数并计算倍率。** 按上一节的方法评估候选 α ，保留选定参数对应的各通道倍率。对过小幅度和倍率设置正数下限，避免除以零或极小值。
3. **变换参数并量化权重。** 若输入来自前序 Norm，将 Norm 的可学习权重及偏置（若有）按通道除以倍率，使其输出直接变为缩放后的激活；再将线性层对应输入通道的权重列乘以倍率，量化并保存权重。参数变换

例如，Norm 输出同时供 Q、K、V 三个线性层使用，三者要共用同一组倍率，权重幅度统计也要覆盖三者；随后都变换对应权重列，才能保持各自的输出不变。通道倍率已合入模型参数，推理时不必再额外执行这次缩放。

三、W8A8 计算与 vLLM 推理

1. 整数点积与输出恢复

图中的 $q_{x,j}, q_{w,j}$ 是激活与权重的 INT8 编码， Δ_x, Δ_w 是各自的量化步长。还原后的数值分别为 $\Delta_x q_{x,j}$ 和 $\Delta_w q_{w,j}$ ，所以：

$$\begin{aligned}\hat{y} &= \sum_j (\Delta_x q_{x,j})(\Delta_w q_{w,j}) \\ &= \Delta_x \Delta_w \sum_j q_{x,j} q_{w,j}.\end{aligned}$$

两侧步长都不随求和位置 j 变化，因此可以先完成整数点积，再乘步长恢复输出；图中的平滑前、后两条路径都按此计算。

输入编码是 INT8，乘积与累加结果却可能超出 INT8 的范围，所以图中使用 INT32 累积。W8A8 描述的是两个操作数的位宽，不是累加结果的位宽。

2. 离线保存与运行时计算

平滑变换与权重量化在离线完成，模型保存变换后的 Norm 参数、INT8 权重及权重尺度。**激活来自当前请求，仍需在每次线性层计算时量化成 INT8。**

以 **vLLM v0.25.1** 的 `compressed-tensors` W8A8 INT8 格式、对称 CUDA/CUTLASS 路径为例：

1. **加载权重与尺度。** 读取 INT8 权重及尺度；静态激活量化模式还读取输入尺度。量化参数
2. **量化当前输入。** 动态模式根据当前输入计算尺度，静态模式使用已加载的尺度；两者都将当前激活编码成 INT8。执行入口
3. **计算并恢复输出。** 内核对 INT8 操作数做矩阵乘法，用 INT32 累积，再应用激活与权重尺度，将结果转回输入的浮点类型。累积类型

Norm、Softmax 等其他操作仍可使用浮点精度。